Laborator 2
Inteligență Artificială

Drd.Limboi Sergiu

Agenda

- Introducere în Învățarea Automată
- Etape în cadrul procesului de Învățare Automată
- Preprocesarea datelor-> Normalizarea datelor
- Discuții Tema 2

ÎNVĂȚAREA AUTOMATĂ

- Învățarea poate fi explicată ca fiind activitatea de a obține cunoștințe sau de a le înțelege, precum și abilitatea de a-ți însuși noțiuni prin studiu, instruire sau experiență
- Învățarea automată (engleză Machine Learning) se referă la modificări din sisteme care realizează sarcini asociate cu diverse teme, concepte din Inteligență Artificială, sarcini precum diagnoză, predicție, planificare, control sau detectare.

ÎNVĂȚAREA AUTOMATĂ

- Scop->proiectarea și dezvoltarea unor algorimit și metode utilizate pentru ca un sistem computațional să "învețe"
- De ce să învețe sistemele informatice?
  - Unele sarcini se pot defini doar prin exemple- de aceea trebuie furnizate perechi de intrări-ieșiri, în absența unor legături concrete între datele de intrare și rezultate
  - Este posibil ca anumite informații ascunse, nedescifrate, să reflecte corelații sau legături
  - Cantitatea mare de informații poate fi dificil de codificat de către mintea umană

ÎNVĂȚAREA AUTOMATĂ

- Pentru a defini conceptele utilizate în problematica învățării se folosește o funcție f, iar sarcina celui care învață este de a ghici forma funcției.
- Tipuri de învățare
  - Supervizată- știm (uneori doar aproximativ) valorile funcției f pentru m cazuri ale unui set de antrenare. Sistemul poate intui, după etapa de antrenare, care ar fi funcția pentru un alt set de date.
  - Nesupervizată-avem doar o mulțime de date pentru care nu știm funcția. Presupune divizarea setului de date în submulțimi sau grupuri. În acest caz valoarea funcției va fi numele subgrupului (clasei) din care setul face parte.
  - Prin întărire (reinforcement learning)- sistemul interacționează cu mediul și poate primi recompense sau penalizări.

Etape în cadrul unui proces de învățare automată

- Colectarea datelor
- Procesarea/Explorarea datelor
- Stabilirea unui model
- Etapa de antrenare (dacă vorbim de învățare supervizată)
- Evaluarea rezultatelor
- Etapa de predicție/clasificare (aplicarea modelului pe un nou set de date)

Etape în cadrul unui proces de învățare automată

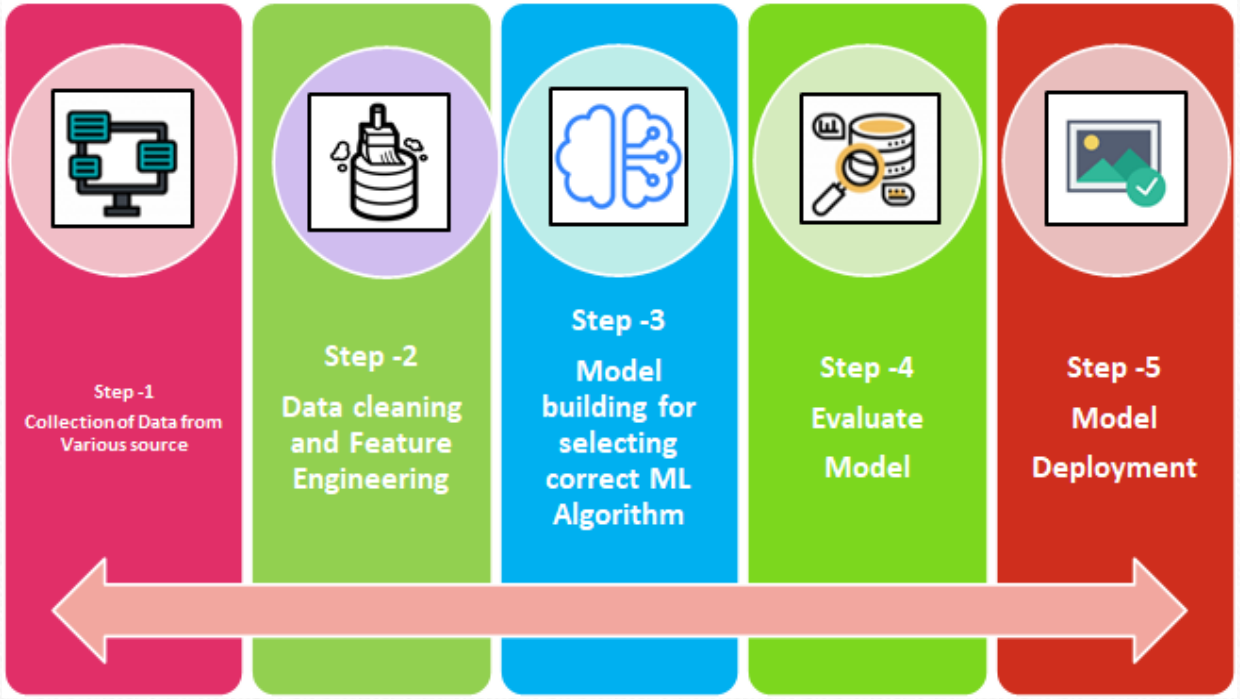

Preprocesarea/Explorarea datelor

- În cadrul acestei etape se analizează datele colectate.
- De exemplu- dacă vorbim de texte este necesară o preprocesare a lor (eliminarea caractelor speciale, punctuație, repetiție, cuvinte colocviale, etc.). Mai multe detalii în laboratoarele următoare
- O sub-etapă importantă este normalizarea datelor (dacă vorbim de valori numerice). Normalizarea implică ajustarea informației la aceeasi scală (același numitor comun).
- Să nu comparăm "mere cu pere"

Normalizarea datelor

- De ex. Avem un set de date care conține informații despre temperaturi. O valoare poate varia (ex. -100, 5, 50, 30, 60 grade Celsius).
- Trebuie să aducem valorile la un numitor comun având în vedere paleta largă de valori
- Există diferite tehnici pentru a normaliza datele
  - Clipping
  - Scalare logaritmică
  - Normalizare de tip min-max
  - Standardizare (normalizare Z) -temă

xi ` = (xi-x barat)/ deviatia standard
x barat = (suma i=1 n din xi) / n

Metoda de tip Clipping

- Definirea unui prag pentru a segmenta datele
- Recomandare de utilizare- atunci când setul de date conţine mulţi outliers (o instanţă a setului este foarte diferită de restul din set- de ex. majoritatea valorilor sunt în intervalul [1,50], iar outliers pot fi 200, 300, 150)

$$x_i^{new} = \begin{cases} x_i, & x_i < threshold \\ threshold, x_i \geq threshold \end{cases}$$

la vreme: 0 -> threshold

la scoala: 5 -> nota 5 de trecere

xi(new) = { xi, xi < threshold
{ threshold, altfel

Scalare logaritmică

- A se utiliza atunci când subsetul/ instanţa are mai multă informaţie sau mai puţină decât restul setului de date.
- "Generally, you use logarithmic scales if the data in your graph represents a large range, such as an exponential growth rate."
- O scalare logaritmică poate proiecta valori de la 10 la 100.000 de ex
- Ex. multe filme sunt evaluate cu note puţine (ratings), iar unele au foarte multe note.

$$x_i^{new} = \log(x_i)$$

Scalare de tip min-max

- Conversia valorilor reale din intervalul lor natural într-unul comun (de obicei [0,1])
- De ex. –dacă avem măsurători ale unor rămăşiţe arheologice umane putem avea valori între 5 şi 100. Aceste valori are oaselor le vom aduce în intervalul [0,1].
- A se utiliza când cunoaştem valorile superioare şi inferioare ale setului şi avem puţini spre deloc outiliers. De asemenea, setul de date este aproximativ uniform distribuit în cadrul intervalului de valori.

$$x_i^{new} = \frac{x_i - min(x)}{max(x) - min(x)}$$